

Limpieza de datos, imputación, escalamiento, codificación de variables, partición train/validation/test y construcción de pipelines.

UNIDAD 1 - MACHINE LEARNING PARA EL ANÁLISIS INTELIGENTE DE DATOS
INTELIGENCIA ARTIFICIAL
(SEMANA 3)

Prof. Dr. Ivar Vargas Belizario

ivargasbelizario@gmail.com



Structured Data vs Unstructured Data

Estructurados

Categorías y Numéricos {Enteros, Reales, Fecha}

No estructurados (complejos)

Imágenes, audios, videos, electrocardiograma, etc.

Credit Card Customers Prediction

Data Card

Code (12)


Discussion (0)

107

New Notebook

Download


Education_Level	Marital_Status	Income_Category	Card_Category	Months_on_book
PFA Data Dictionary	PFA Data Dictionary	PFA Data Dictionary	PFA Data Dictionary	PFA Data Dictionary
Graduate	31%	Married	46%	Less than \$40K
High School	20%	Single	39%	\$40K - \$60K
Other (4986)	49%	Other (1497)	15%	Other (4776)
Unknown	Married	\$120K +	Blue	45
High School	Single	Less than \$40K	Blue	36
High School	Single	\$80K - \$120K	Blue	38
Graduate	Single	\$40K - \$60K	Blue	36
Graduate	Single	\$80K - \$120K	Blue	42
Unknown	Married	Unknown	Blue	28
Graduate	Married	Less than \$40K	Blue	52
Graduate	Married	\$40K - \$60K	Blue	35
Doctorate	Married	\$40K - \$60K	Blue	35
College	Married	\$120K +	Blue	50
Unknown	Married	\$80K - \$120K	Blue	37
College	Single	Unknown	Blue	43



Structured Data vs Unstructured Data


Estructurados

Categorías y Numéricos {Enteros, Reales, Fecha}



No estructurados (complejos)

Imágenes, audios, videos, electrocardiograma, etc.



Prof. Dr. Ivar Vargas Belizario

Flujo de trabajo en proyectos de machine learning.

1. Recolección de datos

2. Definición del problema

3. Limpieza y preprocesamiento

4. Análisis exploratorio de datos (EDA)

5. Selección y entrenamiento del modelo

6. Evaluación del modelo

7. Despliegue (Deployment)

Prof. Dr. Ivar Vargas Belizario

Contenido

1. Limpieza de datos.
2. Imputación.
3. Escalamiento.
4. Codificación de variables.
5. Reducción de la dimensionalidad.
6. Partición train/validation/test.
7. Construcción de pipelines.

Contenido

1. Limpieza de datos.
2. Imputación.
3. Escalamiento.
4. Codificación de variables.
5. Reducción de la dimensionalidad.
6. Partición train/validation/test.
7. Construcción de pipelines.

Preprocesamiento de Datos

- Etapa crítica en proyectos de Machine Learning
- Transforma datos crudos en datos utilizables
- Impacta directamente en el rendimiento del modelo
- Incluye limpieza, transformación y organización de datos

Limpieza de Datos

- Eliminación de registros duplicados
- Corrección de errores tipográficos o inconsistencias
- Detección y tratamiento de outliers
- Manejo de datos irrelevantes o ruido
- Ejemplo: valores negativos en edad → corregir o eliminar

Problemas comunes en los datos

- Valores faltantes (NaN, NULL)
- Datos duplicados
- Outliers (valores atípicos)
- Inconsistencias (formatos, unidades)
- Errores tipográficos


Contenido

1. Limpieza de datos.
2. Imputación.
3. Escalamiento.
4. Codificación de variables.
5. Reducción de la dimensionalidad.
6. Partición train/validation/test.
7. Construcción de pipelines.

Imputación de Datos Faltantes

- Problema común en datasets reales
- Técnicas:
 - Media (datos numéricos)
 - Mediana (robusto a outliers)
 - Moda (variables categóricas)
 - Modelos predictivos (KNN, regresión)
- Evita pérdida de información al eliminar filas

Data Imputation



Contenido

1. Limpieza de datos.
2. Imputación.
3. Escalamiento.
4. Codificación de variables.
5. Reducción de la dimensionalidad.
6. Partición train/validation/test.
7. Construcción de pipelines.

13

Escalamiento.

Escalamiento de Variables

- Necesario para algoritmos sensibles a magnitudes:
 - KNN, SVM, Redes Neuronales
- Técnicas principales:
 - **Normalización (Min-Max):** rango $[0,1]$
 - **Estandarización:** media = 0, desviación estándar = 1
- Mejora la convergencia del modelo

Contenido

1. Limpieza de datos.
2. Imputación.
3. Escalamiento.
4. Codificación de variables.
5. Reducción de la dimensionalidad.
6. Partición train/validation/test.
7. Construcción de pipelines.

15

Codificación de variables.

Codificación de Variables Categóricas

- Convierte texto en valores numéricos
- Métodos:
 - Label Encoding (ordinal)
 - One-Hot Encoding (no ordinal)
- Evita interpretaciones erróneas del modelo
- Ejemplo: “Rojo, Azul, Verde” → vectores binarios

Contenido

1. Limpieza de datos.
2. Imputación.
3. Escalamiento.
4. Codificación de variables.
5. Reducción de la dimensionalidad.
6. Partición train/validation/test.
7. Construcción de pipelines.

17

Reducción de la dimensionalidad.

¿Qué es la Reducción de Dimensionalidad?

- Proceso de transformar datos de alta dimensión:

$$X \in \mathbb{R}^{n \times d} \rightarrow Z \in \mathbb{R}^{n \times k}, k < d \quad \text{with } X \in \mathbb{R}^{n \times d} \rightarrow Z \in \mathbb{R}^{n \times k}, \quad \text{with } k < d$$

- Objetivos:
 - Reducir complejidad
 - Eliminar redundancia
 - Mejorar generalización

Tipos de Métodos

- **Selección de características (Features Selection)**
 - Elimina variables irrelevantes
- **Extracción de características (Features Extraction)**
 - Proyecta datos a nuevo espacio

Motivación

- Problema de la “**maldición de la dimensionalidad**”
- A mayor dimensión:
 - Más datos necesarios
 - Mayor riesgo de overfitting
 - Mayor costo computacional
- Mejora:
 - Generalización
 - Visualización (2D/3D)

PCA

- Análisis de Componentes Principales

t-SNE

- Visualización no lineal


UMAP

- Preserva estructura global y local

GFF

- Graphs from Features, interactive selection of features by relevance based in graphs

<https://ivarvb.github.io/GFF>




Prof. Dr. Ivar Vargas Belizario

Contenido

1. Limpieza de datos.
2. Imputación.
3. Escalamiento.
4. Codificación de variables.
5. Reducción de la dimensionalidad.
6. Partición train/validation/test.
7. Construcción de pipelines.

Partición del Dataset

- Separación para evaluar correctamente el modelo:
 - **Train (70–80%)** → entrenamiento
 - **Validation (10–15%)** → ajuste de hiperparámetros
 - **Test (10–15%)** → evaluación final
- Evita sobreajuste (overfitting)



Contenido

1. Limpieza de datos.
2. Imputación.
3. Escalamiento.
4. Codificación de variables.
5. Reducción de la dimensionalidad.
6. Partición train/validation/test.
7. Construcción de pipelines.

Construcción de Pipelines

- Automatiza el flujo de procesamiento
- Encadena pasos:
 - Limpieza → Transformación → Modelo
- Ventajas:
 - Reproducibilidad
 - Menor error humano
 - Código más limpio y modular

Trabajo en clase (Grupos de hasta 5 estudiantes)

Construcción de Pipelines

- Definir:
 - El problema.
 - El objetivo (clasificación, regresión, etc)

<https://www.kaggle.com/competitions/shelter-animal-outcomes>

Melanoma:

<https://www.kaggle.com/datasets/wanderdust/skin-lesion-analysis-toward-melanoma-detection>

Garbage classification:

<https://www.kaggle.com/datasets/sumn2u/garbage-classification-v2>

<https://www.kaggle.com/datasets/asdasdasdasdas/garbage-classification>

Prof. Dr. Ivar Vargas Belizario



¡Gracias!

Limpieza de datos, imputación, escalamiento, codificación de variables, partición train/validation/test y construcción de pipelines.

UNIDAD 1 - MACHINE LEARNING PARA EL ANÁLISIS INTELIGENTE DE DATOS
INTELIGENCIA ARTIFICIAL
(SEMANA 3)

Prof. Dr. Ivar Vargas Belizario

ivargasbelizario@gmail.com

