

Clustering: k-means y agrupamiento jerárquico.
Introducción a interpretabilidad, sesgo y ética en datos.
Taller integrador de machine learning.

UNIDAD 1 - MACHINE LEARNING PARA EL ANÁLISIS INTELIGENTE DE DATOS
INTELIGENCIA ARTIFICIAL
(SEMANA 5)

Prof. Dr. Ivar Vargas Belizario

ivargasbelizario@gmail.com



Structured Data vs Unstructured Data

Estructurados

Categorías y Numéricos {Enteros, Reales, Fecha}

No estructurados (complejos)

Imágenes, audios, videos, electrocardiograma, etc.


Credit Card Customers Prediction

Data CardCode (12)Discussion (0)

107New Notebook

Download


Education_Level	Marital_Status	Income_Category	Card_Category	Months_on_book			
Graduate	31%	Married	46%	Less than \$40K	35%	Blue	93%
High School	20%	Single	39%	\$40K - \$60K	18%	Silver	5%
Other (4986)	49%	Other (1497)	15%	Other (4776)	47%	Other (136)	1%
Unknown	Married	\$120K +	Blue	45			
High School	Single	Less than \$48K	Blue	36			
High School	Single	\$88K - \$128K	Blue	38			
Graduate	Single	\$48K - \$68K	Blue	36			
Graduate	Single	\$88K - \$128K	Blue	42			
Unknown	Married	Unknown	Blue	28			
Graduate	Married	Less than \$48K	Blue	52			
Graduate	Married	\$48K - \$68K	Blue	35			
Doctorate	Married	\$48K - \$68K	Blue	35			
College	Married	\$120K +	Blue	50			
Unknown	Married	\$88K - \$128K	Blue	37			
College	Single	Unknown	Blue	43			



Structured Data vs Unstructured Data


Estructurados

Categorías y Numéricos {Enteros, Reales, Fecha}



No estructurados (complejos)

Imágenes, audios, videos, electrocardiograma, etc.



Prof. Dr. Ivar Vargas Belizario

Contenido

1. Clustering: k-means y agrupamiento jerárquico.
2. Introducción a interpretabilidad, sesgo y ética en datos.
3. Taller integrador de machine learning.

Contenido

1. Clustering: k-means y agrupamiento jerárquico.
2. Introducción a interpretabilidad, sesgo y ética en datos.
3. Taller integrador de machine learning.

Clustering: k-means y agrupamiento jerárquico



¿Qué es el clustering?

- Técnica de aprendizaje **no supervisado**
- Agrupa datos según **similitud**
- No requiere etiquetas previas
- Objetivo: descubrir **patrones ocultos**

Aplicaciones:

- Segmentación de clientes
- Análisis de imágenes
- Detección de anomalías

Clustering: k-means y agrupamiento jerárquico





number of clusters number of cases case i centroid for cluster j

objective function $\leftarrow J = \sum_{j=1}^k \sum_{i=1}^n \underbrace{\|x_i^{(j)} - c_j\|^2}_{\text{Distance function}}$

Prof. Dr. Ivar Vargas Belizario

Clustering: k-means y agrupamiento jerárquico





number of clusters number of cases case i centroid for cluster j

objective function $\leftarrow J = \sum_{j=1}^k \sum_{i=1}^n \underbrace{\|x_i^{(j)} - c_j\|^2}_{\text{Distance function}}$

Prof. Dr. Ivar Vargas Belizario

Clustering: k-means y agrupamiento jerárquico





number of clusters number of cases case i centroid for cluster j

$$\text{objective function} \leftarrow J = \sum_{j=1}^k \sum_{i=1}^n \|x_i^{(j)} - c_j\|^2$$

Distance function

Prof. Dr. Ivar Vargas Belizario

Clustering: k-means y agrupamiento jerárquico



k = is indicated by the user

number of clusters number of cases case i centroid for cluster j

$$\text{objective function} \leftarrow J = \sum_{j=1}^k \sum_{i=1}^n \|x_i^{(j)} - c_j\|^2$$

Distance function

Prof. Dr. Ivar Vargas Belizario

Clustering Jerárquico

Tipos:

- Aglomerativo (bottom-up)
- Divisivo (top-down)

Proceso:

- Cada punto inicia como cluster individual
- Se van uniendo según distancia

 Representación:

- **Dendrograma**

 Métricas comunes:

- Distancia euclidiana
- Enlace completo, simple, promedio

 Ventajas:

- No requiere definir K inicialmente

 Limitaciones:

- Costoso computacionalmente

Agglomerative

Divisive



Contenido

1. Clustering: k-means y agrupamiento jerárquico.
2. Introducción a interpretabilidad, sesgo y ética en datos.
3. Taller integrador de machine learning.

13

Introducción a interpretabilidad, sesgo y ética en datos.

Interpretabilidad

¿Por qué importa?

- Comprender decisiones del modelo
- Generar confianza
- Cumplir regulaciones

Tipos:

- Interpretabilidad global
- Interpretabilidad local

Técnicas:

- Feature importance
- SHAP (global)
- LIME (local)

Aspecto	Global	Local
Alcance	Todo el modelo	Una predicción específica
Nivel de detalle	General	Muy detallado
Uso principal	Comprensión global, auditoría	Explicación individual

Feature importance





Fig. 1. One minute spectrograms labeled with the dominant events: (a) frogs, (b) birds and (c) insects. In the figures we can observe background noise, which can be a sound another event happening in parallel to an event of interest.


Introducción a interpretabilidad, sesgo y ética en datos.



<https://doi.org/10.1016/j.ecolind.2020.107316>

Prof. Dr. Ivar Vargas Belizario

Introducción a interpretabilidad, sesgo y ética en datos.



<https://doi.org/10.1016/j.ecolind.2020.107316>

Prof. Dr. Ivar Vargas Belizario

Sesgo en los Datos

¿Qué es el sesgo?

Errores sistemáticos que afectan decisiones del modelo

 Tipos:

- Sesgo de muestreo
- Sesgo histórico
- Sesgo de medición

 Impacto:

- Discriminación
- Modelos injustos

Ética en Ciencia de Datos

Principios clave:

- Transparencia
- Equidad
- Responsabilidad

 Casos reales:

- Algoritmos de contratación
- Sistemas de crédito
- Reconocimiento facial

Contenido

1. Clustering: k-means y agrupamiento jerárquico.
2. Introducción a interpretabilidad, sesgo y ética en datos.
3. Taller integrador de machine learning.

21

Taller integrador de machine learning.

Objetivo:

Aplicar un flujo completo de ML

Pasos:

1. Selección de dataset real
2. Limpieza y preprocesamiento
3. Modelado (supervisado o no supervisado)
4. Evaluación

Notebook

<https://www.kaggle.com/code/ivarvb/unaj26004>



UNIVERSIDAD NACIONAL DE JULIACA ¡Gracias!

**Clustering: k-means y agrupamiento jerárquico.
Introducción a interpretabilidad, sesgo y ética en datos.
Taller integrador de machine learning.**

UNIDAD 1 - MACHINE LEARNING PARA EL ANÁLISIS INTELIGENTE DE DATOS
INTELIGENCIA ARTIFICIAL
(SEMANA 5)

Prof. Dr. Ivar Vargas Belizario

ivargasbelizario@gmail.com

